

Projet Data & Énergie

Prédiction de courbes de consommation client

1 Présentation du projet

Ce projet porte sur l'analyse et la modélisation de courbes de consommation électrique issues de données fictives Enedis. L'objectif général est de développer des modèles capables de travailler sur des courbes de charge au pas de 30 minutes.

La partie présentée ici concerne la prédiction de consommation.

L'objectif est le suivant :

À partir de l'historique de consommation d'un client donné, prédire sa consommation future à court terme.

Le modèle final travaille au niveau client, c'est-à-dire au niveau du `pdl_id`. Il ne prédit donc pas une consommation agrégée, mais bien une courbe de consommation future personnalisée pour chaque client.

2 Données utilisées

Le projet utilise deux fichiers principaux :

RES2-6-9.csv
RES2-6-9-labels.csv

Le fichier de consommation contient les courbes de charge au pas de 30 minutes.

Après chargement, les colonnes utilisées sont :

- `pdl_id` : identifiant du client / point de livraison ;
- `horodate` : date et heure de la mesure ;
- `puissance_w` : puissance appelée en watts.

Le fichier de labels contient les classes de clients :

- `pdl_id` ;
- `label_rs_rp` ;
- `cluster_ref`.

La convention utilisée est :

- 0 = RS : résidence secondaire ;
- 1 = RP : résidence principale.

La puissance est convertie en énergie par pas de 30 minutes :

$$\text{kWh} = \frac{\text{puissance_w} \times 0,5}{1000}$$

car chaque mesure correspond à une demi-heure.

3 Objectif de prédiction

La formulation finale retenue est :

14 jours passés d'un client $\longrightarrow$ 2 jours futurs du même client

Les données étant au pas de 30 minutes :

```
INPUT_LEN = 672 # 14 jours x 48 demi-heures
HORIZON = 96 # 2 jours x 48 demi-heures
```

Chaque exemple d'apprentissage contient donc :

- X = 672 valeurs passées de consommation du client ;
- Y = 96 valeurs futures à prédire.

Ce choix a été retenu car la prédiction individuelle à 7 jours était trop instable, notamment pour les résidences secondaires. Un horizon plus court de 2 jours permet d'obtenir une prévision plus fiable tout en conservant une prédiction de courbe au pas de 30 minutes.

4 Construction des exemples

Pour chaque client, le programme construit des fenêtres temporelles glissantes.

Le paramètre utilisé est :

```
STRIDE = 48
```

Cela signifie que l'on crée un exemple tous les jours, car 48 demi-heures correspondent à une journée.

Exemple pour un client :

- Fenêtre 1 :

X = jours 1 à 14, Y = jours 15 à 16

- Fenêtre 2 :

X = jours 2 à 15, Y = jours 16 à 17

- Fenêtre 3 :

X = jours 3 à 16, Y = jours 17 à 18

Chaque fenêtre est ensuite associée à une date de début de prédiction appelée `forecast_start`.

5 Features utilisées

Pour chaque exemple, le modèle utilise deux types d'informations :

```
X_tab = [X_seq, X_extra]
```

avec :

- `X_seq` : courbe brute des 14 jours passés ;
- `X_extra` : variables explicatives supplémentaires.

5.1 Courbe brute passée

`X_seq` contient les 672 valeurs de consommation du client sur les 14 jours précédant la prédiction. Ces valeurs sont exprimées en kWh par demi-heure.

5.2 Variables calendaires

Ces variables décrivent le début de la période à prédire :

```
dow_sin  
dow_cos  
is_weekend_start  
month_sin  
month_cos  
is_holiday_start  
is_school_holiday_proxy  
season_winter  
season_spring  
season_summer  
season_autumn
```

Elles permettent au modèle de tenir compte des effets liés au jour de la semaine, au week-end, au mois, aux jours fériés, aux périodes de vacances et à la saison.

5.3 Variables RP / RS

Le type de client est ajouté sous forme de variables binaires :

```
is_RS  
is_RP
```

Cela permet au modèle de distinguer les comportements des résidences principales et des résidences secondaires.

5.4 Lags individuels

Les lags sont calculés pour chaque client :

- lag_1 : consommation 30 minutes avant
- lag_48 : même créneau la veille
- lag_96 : même créneau il y a 2 jours
- lag_336 : même créneau il y a 7 jours
- lag_672 : même créneau il y a 14 jours

5.5 Statistiques sur l'historique

Des statistiques sont calculées sur plusieurs fenêtres passées :

- 1 jour
- 2 jours
- 7 jours
- 14 jours

Pour chaque fenêtre, on calcule :

- moyenne
- écart-type
- minimum
- maximum
- somme d'énergie

Ces variables décrivent le niveau de consommation récent du client.

5.6 Variables d'activité passée

Le modèle utilise aussi des indicateurs d'activité passée :

```
active_rate_1d
active_rate_2d
active_rate_7d
active_rate_14d
active_days_rate_7d
active_days_rate_14d
active_days_count_7d
active_days_count_14d
longest_active_run_14d
daily_energy_7d_mean
daily_energy_7d_std
daily_energy_14d_mean
daily_energy_14d_std
weekend_energy_14d
weekday_energy_14d
weekend_over_weekday_energy
```

Une demi-heure est considérée comme active si la consommation dépasse un seuil. Un jour est considéré comme actif si son énergie totale dépasse un seuil journalier.

Ces features sont importantes pour donner des informations sur la présence ou l'absence du client.

5.7 Comparaisons de niveaux récents

Le notebook ajoute enfin des ratios et différences entre niveaux récents :

```
ratio_mean_7d_14d
ratio_mean_2d_7d
ratio_mean_1d_7d
diff_mean_7d_14d
diff_mean_2d_7d
diff_mean_1d_7d
```

Ces variables indiquent si la consommation est en hausse ou en baisse dans les jours précédant la prédiction.

6 Baselines

Deux baselines sont utilisées.

6.1 Baseline récente

Elle consiste à prédire les deux prochains jours en recopiant les deux derniers jours observés. Cette baseline permet de renseigner sur l'état récent du client.

$$\hat{Y}_{\text{recent}} = \text{deux derniers jours observés}$$

6.2 Baseline hebdomadaire

Elle consiste à reprendre la même période de la semaine précédente. Cette baseline exploite la périodicité hebdomadaire.

$$\hat{Y}_{\text{weekly}} = \text{mêmes créneaux une semaine avant}$$

Dans les résultats obtenus, la baseline récente est meilleure que la baseline hebdomadaire pour un horizon de 2 jours.

7 Modèles entraînés

Trois types de méthodes sont comparés.

7.1 Baselines

Deux baselines personnalisées sont utilisées :

- la baseline récente, qui recopie les deux derniers jours observés
- la baseline hebdomadaire, qui reprend les mêmes créneaux de la semaine précédente.

La baseline récente est retenue comme baseline de référence pour les modèles résiduels, car elle obtient de meilleurs résultats en validation que la baseline hebdomadaire.

7.2 Ridge résiduel

Le modèle Ridge ne prédit pas directement la courbe future. Il apprend une correction à appliquer à la baseline récente.

On définit :

$$\text{résidu} = \text{vraie courbe future} - \text{baseline}$$

Puis le modèle apprend à prédire ce résidu. La prédiction finale est donc :

$$\hat{Y} = Y_{\text{baseline}} + \hat{R}$$

avec $\hat{R}$ le résidu prédit par le modèle Ridge.

Cette approche permet de conserver la force de la baseline récente tout en corrigeant ses erreurs systématiques. Le meilleur hyperparamètre obtenu est :

$$\alpha = 1$$

7.3 CNN 1D résiduel

Un réseau de neurones convolutionnel 1D est également testé. Il prend en entrée :

- la courbe passée du client sur 14 jours ;
- les variables explicatives supplémentaires.

Comme le modèle Ridge, le CNN apprend une correction à appliquer à la baseline récente :

$$\hat{Y} = Y_{\text{baseline}} + \hat{R}_{CNN}$$

Le modèle CNN est volontairement léger afin de limiter le temps de calcul.

8 Séparation train / validation / test

La séparation est temporelle, et non aléatoire.

Le schéma est :

train | gap | validation | gap | test

Les paramètres sont :

<pre>N_VAL_DAYS = 30 N_TEST_DAYS = 30 GAP_DAYS = 2</pre>
--

Le test correspond aux 30 derniers jours de départ de prédiction. La validation correspond aux 30 jours précédant le test. Le train contient toutes les fenêtres disponibles avant la validation.

Le gap de 2 jours est nécessaire car l'horizon prédit est de 2 jours. Il évite que les variables cibles d'un ensemble chevauchent la période suivante.

9 Métriques utilisées

Plusieurs métriques sont calculées pour évaluer les prédictions. On note y_i la consommation réelle au pas de temps i , $\hat{y}_i$ la consommation prédite, et n le nombre total de points évalués.

9.1 MAE

La MAE, ou erreur absolue moyenne, mesure l'écart moyen entre la prédiction et la valeur réelle :

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Elle est exprimée en kWh par demi-heure. Plus elle est faible, meilleure est la prédiction.

9.2 RMSE

La RMSE, ou racine de l'erreur quadratique moyenne, pénalise davantage les grosses erreurs :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Elle est aussi exprimée en kWh par demi-heure. Une RMSE nettement supérieure à la MAE indique la présence de quelques erreurs importantes.

9.3 WMAPE

Le WMAPE est la métrique principale utilisée dans ce projet. Il rapporte la somme des erreurs absolues à la somme des consommations réelles :

$$\text{WMAPE} = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|} \times 100$$

Cette métrique est plus stable que le MAPE classique lorsque certaines consommations sont très faibles.

9.4 MAPE filtré

Le MAPE classique est défini par :

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Cependant, cette métrique devient instable lorsque y_i est proche de zéro. Par exemple, une faible erreur absolue peut donner une erreur relative très élevée si la consommation réelle est presque nulle.

On utilise donc aussi un MAPE filtré, calculé uniquement sur les points où la consommation réelle dépasse un seuil s :

$$\text{MAPE filtré} = \frac{100}{|\mathcal{I}_s|} \sum_{i \in \mathcal{I}_s} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

avec :

$$\mathcal{I}_s = \{i \mid y_i > s\}$$

Dans le notebook, le seuil utilisé est :

$$s = 0,10 \text{ kWh}$$

9.5 sMAPE

Le sMAPE est une variante symétrique du MAPE :

$$\text{sMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|) / 2}$$

Il limite certains défauts du MAPE classique, mais il reste sensible aux faibles valeurs de consommation. Il est donc utilisé comme métrique secondaire.

9.6 Choix des métriques

Dans ce projet, le WMAPE est privilégié pour comparer les modèles, car il donne une erreur relative globale plus robuste lorsque les consommations sont faibles. La MAE et la RMSE permettent de mesurer l'erreur absolue en kWh. Le MAPE filtré permet d'analyser l'erreur relative seulement sur les périodes où la consommation réelle est significative. Le MAPE classique n'est pas mis au centre de l'analyse, car il devient instable quand la consommation réelle est proche de zéro.

10 Résultats principaux

La meilleure méthode obtenue est le modèle Ridge résiduel, sans module supplémentaire de classification d'activité future.

Les résultats globaux sur le test final sont les suivants :

Méthode	MAE	RMSE	WMAPE	MAPE filtré
Baseline récente	0.163	0.313	66.04 %	66.13 %
Baseline hebdomadaire	0.183	0.340	74.29 %	74.00 %
Ridge résiduel	0.152	0.241	61.76 %	57.69 %
CNN 1D résiduel	0.164	0.291	66.43 %	64.94 %

TABLE 1 – Résultats globaux sur le test final.

Le Ridge résiduel améliore la baseline récente, avec un WMAPE qui passe d'environ 66.04 % à 61.76 %. Il obtient aussi la meilleure RMSE, ce qui indique une réduction des erreurs importantes.

Le CNN 1D résiduel a également été testé, mais il ne dépasse pas la baseline récente ni le Ridge résiduel dans cette configuration. Cela montre que l'augmentation de la complexité du modèle ne garantit pas une meilleure performance sur ce problème.

11 Interprétation des résultats

La prédiction individuelle est beaucoup plus difficile que la prédiction agrégée.

Au niveau d'un seul client, la consommation dépend fortement de la présence ou de l'absence future. Cette information n'est pas directement disponible dans les données.

Exemple difficile :

- 14 jours passés : client absent ;
- 2 jours futurs : client présent.

Dans ce cas, le modèle ne peut pas parfaitement anticiper le changement de comportement.

Les résultats sont meilleurs sur les résidences principales que sur les résidences secondaires, car les RP ont en général des profils plus réguliers.

12 Limites

Les principales limites sont :

- le test final couvre une période continue de 30 jours et pas toute l'année
- la présence future réelle du client est inconnue
- le MAPE classique est peu pertinent à cause des faibles consommations

Le jeu de données est déséquilibré :

- RS : 428 clients
- RP : 72 clients.

13 Fonction de prédiction finale

Le notebook contient une fonction permettant de générer une prédiction pour un client :


```
predict_next_2_days_for_client(pdl_id, model_name=None)
```

Elle renvoie un DataFrame contenant :

```
horodate  
prediction_kwh  
pdl_id  
segment  
modele
```

Cette fonction correspond au cas d'usage final : donner un client et obtenir sa courbe de consommation prévue pour les deux prochains jours.

14 Conclusion

Le modèle final prédit la consommation future au niveau client, à partir de son historique individuel. La meilleure méthode est un modèle Ridge résiduel.

Les résultats montrent une amélioration par rapport aux baselines simples, mais confirment aussi que la prévision individuelle reste difficile, notamment pour les résidences secondaires.

La principale limite vient du fait que la présence future du client, qui influence fortement sa consommation, n'est pas connue directement.

14.1 Dictionnaire des variables explicatives

Les variables supplémentaires, notées **X_{extra}**, complètent la courbe brute passée **X_{seq}**. Elles sont toutes calculées uniquement à partir des informations disponibles avant le début de la période prédite, ou à partir de la date de début de prédiction. Elles ne contiennent donc pas d'information issue des deux jours futurs à prédire.

Variables calendaires

dow_sin, dow_cos Encodage cyclique du jour de la semaine. Cela permet de représenter correctement le caractère cyclique du calendrier, par exemple le fait que le dimanche et le lundi sont proches.

is_weekend_start Variable binaire qui vaut 1 si le début de la prédiction tombe un samedi ou un dimanche, 0 sinon.

month_sin, month_cos Encodage cyclique du mois de l'année, utilisé pour tenir compte de la saisonnalité.

is_holiday_start Variable binaire indiquant si le jour de début de prédiction est un jour férié.

is_school_holiday_proxy Approximation indiquant si la date se situe dans une période probable de vacances scolaires.

season_winter, season_spring, season_summer, season_autumn Variables binaires indiquant la saison au début de la période prédite.

Variables liées au type de client

`is_RS` Variable binaire qui vaut 1 si le client est identifié comme résidence secondaire, 0 sinon.

`is_RP` Variable binaire qui vaut 1 si le client est identifié comme résidence principale, 0 sinon.

Lags individuels

`lag_1` Consommation du dernier pas de temps disponible, soit 30 minutes avant le début de la prédiction.

`lag_48` Consommation au même créneau horaire la veille.

`lag_96` Consommation au même créneau horaire deux jours avant.

`lag_336` Consommation au même créneau horaire une semaine avant.

`lag_672` Consommation au même créneau horaire quatorze jours avant.

Ces lags ne constituent pas une nouvelle source de données : ils extraient explicitement certaines valeurs importantes de la courbe passée. Ils sont surtout utiles pour les modèles tabulaires comme le Ridge, car ils mettent directement à disposition des références temporelles importantes.

Statistiques sur l'historique

`mean_1d`, `mean_2d`, `mean_7d`, `mean_14d` Consommation moyenne sur les 1, 2, 7 ou 14 derniers jours.

`std_1d`, `std_2d`, `std_7d`, `std_14d` Écart-type de la consommation sur les fenêtres passées. Il mesure la variabilité récente.

`min_1d`, `min_2d`, `min_7d`, `min_14d` Consommation minimale observée sur les fenêtres passées.

`max_1d`, `max_2d`, `max_7d`, `max_14d` Consommation maximale observée sur les fenêtres passées.

`sum_1d`, `sum_2d`, `sum_7d`, `sum_14d` Énergie totale consommée sur les fenêtres passées.

Variables d'activité passée

`active_rate_1d`, `active_rate_2d`, `active_rate_7d`, `active_rate_14d` Part des demi-heures considérées comme actives sur les fenêtres passées. Une demi-heure est active si la consommation dépasse un seuil.

`active_days_rate_7d`, `active_days_rate_14d` Part des jours considérés comme actifs sur les 7 ou 14 derniers jours.

`active_days_count_7d`, `active_days_count_14d` Nombre de jours actifs sur les 7 ou 14 derniers jours.

`longest_active_run_14d` Plus longue série de jours actifs consécutifs sur les 14 derniers jours.

`daily_energy_7d_mean`, `daily_energy_14d_mean` Énergie journalière moyenne sur les 7 ou 14 derniers jours.

`daily_energy_7d_std`, `daily_energy_14d_std` Variabilité de l'énergie journalière sur les 7 ou 14 derniers jours.

weekend_energy_14d Énergie totale consommée pendant les week-ends des 14 derniers jours.

weekday_energy_14d Énergie totale consommée pendant les jours de semaine des 14 derniers jours.

weekend_over_weekday_energy Rapport entre la consommation du week-end et celle des jours de semaine. Il aide à repérer des profils plus actifs le week-end.

Ces variables donnent une estimation indirecte de l'activité passée du client. Elles ne permettent pas de connaître sa présence future, mais elles aident le modèle à repérer si le client était récemment actif ou non.

Comparaisons de niveaux récents

ratio_mean_7d_14d Rapport entre la consommation moyenne des 7 derniers jours et celle des 14 derniers jours.

ratio_mean_2d_7d Rapport entre la consommation moyenne des 2 derniers jours et celle des 7 derniers jours.

ratio_mean_1d_7d Rapport entre la consommation moyenne du dernier jour et celle des 7 derniers jours.

diff_mean_7d_14d Différence entre la consommation moyenne des 7 derniers jours et celle des 14 derniers jours.

diff_mean_2d_7d Différence entre la consommation moyenne des 2 derniers jours et celle des 7 derniers jours.

diff_mean_1d_7d Différence entre la consommation moyenne du dernier jour et celle des 7 derniers jours.